

一，创建 github 账号并加入

二，部署以及环境要求

在课程环境或本组环境中启动 SGLangOpenAI-compatible 服务，能访问 /v1/models，并完成一次推理请求。

第一步：准备环境

建议 Ubuntu / WSL。

环境要求：

Python 3.12

SGLang **0.5.14**

Ray **2.56.0**

模型 **Qwen/Qwen3-0.6B**

并且 SGLang 和 Ray 可以放在不同 Python 环境，通过 HTTP 通信。

第二步：创建 SGLang 环境

安装：

```
pip install sglang==0.5.14
```

第三步：启动第一个 SGLang 服务

使用要求的模型：

Qwen/Qwen3-0.6B

启动：

```
python -m sglang.launch_server \
--model-path Qwen/Qwen3-0.6B \
--host 0.0.0.0 \
--port 30000
```

第一次会下载模型。

新开终端。

测试模型列表：

```
curl http://localhost:30000/v1/models
```

要求需要截图（截图 1）保存这个结果。

第四步：创建 Ray 环境

安装：

```
pip install ray==2.56.0
```

三，考试内容

1. 发送一次推理请求并截图保存（截图 2）
2. Mooncake trace 采样 workload
从 Mooncake FAST'25 trace 中采样 10-30 条请求记录，例如 `arxiv-trace/mooncake_trace.jsonl`。根据 `input_length` 和 `output_length` 构造 synthetic prompt，用 Poisson 到达过程生成请求时间，并将这组小 workload 发送到 SGLang。记录每个请求的 input tokens、output tokens、status、TTFT 或 latency。截图保存（截图 3）
3. 用一张流程图讲清一次请求如何经过 SGLang 在线推理框架，重点放在流程上
4. 重点回答：
 - SGLang 的 RadixAttention / RadixCache 解决什么问题？
 - SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？
 - vLLM 的 PagedAttention 解决什么问题？它和 SGLang 的 RadixAttention / paged KV 机制有什么联系与差异？答案文件不超过一页

四．最终交付

提交一个压缩包，包含：

1. 将截图 1，2，3 放在同一个 pdf 文件，命名为操作保存.pdf
2. 流程图.pdf
3. 重点回答.pdf
4. 阅读笔记.pdf

五．参考文献

SGLang Documentation: <https://docs.sglang.ai/>

- SGLang / RadixAttention Paper (NeurIPS 2024):

https://papers.nips.cc/paper_files/paper/2024/hash/724be4472168f31ba1c9ac630f15dec8-Abstract-Conference.html

- vLLM Documentation: <https://docs.vllm.ai/>

- vLLM / PagedAttention Paper (SOSP 2023):

<https://dl.acm.org/doi/10.1145/3600006.3613165>

- Mooncake FAST'25 Trace Release: <https://github.com/kvcache-ai/Mooncake/tree/main/FAST25-release>